Autómatas y Lenguajes Formales 2016-1

Maestría en Ciencia e Ingeniería de la Computación UNAM

Tema 8: Gramáticas, jerarquía de Chomsky, ambigüedad

Dr. Favio Ezequiel Miranda Perea

favio@ciencias.unam.mx

Facultad de Ciencias UNAM

29 de enero de 2020

Gramáticas

Introducción

- Un mecanismo relevante para generar un lenguaje es mediante el concepto de gramática formal.
- Las gramáticas formales fueron introducidas por Noam Chomsky en 1956.
- La intención era tener un modelo para la descripción de lenguajes naturales.
- Posteriormente se utilizaron como herramienta para presentar la sintaxis de lenguajes de programación y para el diseño de analizadores léxicos de compiladores

Gramáticas

Definición

Una gramática es una cuaterna $G = \langle V, T, S, P \rangle$ tal que:

- V es un alfabeto de variables o símbolos no-terminales, los cuales se denotan con mayúsculas $A, B, C, \ldots$
- T es un alfabeto de símbolos terminales, los cuales se denotan con minúsculas $a, b, c, \ldots$. Además se requiere $T \cap V = \varnothing$.
- $S \in V$ es una variable distinguida llamada el símbolo inicial.
- P es un conjunto finito de reglas de reescritura, llamadas reglas de producción o producciones.

Reglas de Producción

Gramáticas

El conjunto de reglas de producción P es un conjunto finito de pares $\langle \alpha, \beta \rangle$ tales que

- $\alpha \in (V \cup T)^\star - T^\star$. Es decir, α es una cadena de símbolos terminales ó no terminales, con al menos un símbolo no-terminal.
- $\beta \in (V \cup T)^\star$. Es decir, β es una cadena de símbolos de $V \cup T$, los cuales podrían ser todos terminales.
- Usualmente en vez de escribir $\langle \alpha, \beta \rangle \in P$ escribimos

$$\alpha \to \beta$$

y decimos que α produce a β, o que α se reescribe en β.

Derivaciones

Generación de cadenas

Las reglas de producción sirven para generar cadenas, proceso que se formaliza mediante las derivaciones formales:
Dadas dos palabras $w, v \in (V \cup T)^\star$ decimos que v es derivable a partir de w en un paso ($w \to v$) si y sólo si:

- Existe una regla $\alpha \to \beta$ en P y cadenas $\gamma_1, \gamma_2 \in (V \cup T)^\star$ tales que:

$$w = \gamma_1 \alpha \gamma_2 \quad \text{y} \quad v = \gamma_1 \beta \gamma_2$$

- Algunos autores utilizan $\Rightarrow$ en vez de $\to$ para denotar la relación de derivación. Nosotros preferimos sobrecargar el operador $\to$.

Derivaciones formales

$\to^*$

Decimos que una cadena v es derivable a partir de w si existen palabras $\gamma_2, \ldots, \gamma_n$ tales que

$$w = \gamma_1 \to \gamma_2 \ldots \gamma_{n+1} \to \gamma_n = v$$

En tal caso escribimos $w \to^* v$.

Lenguaje generado por una gramática

$L(G)$

Dada una gramática $G = \langle V, T, S, P \rangle$ definimos al lenguaje generado por G, denotado $L(G)$, como el conjunto de palabras de símbolos terminales derivables a partir del símbolo inicial S. Es decir,

$$L(G) = \{w \in T^\star \mid S \rightarrow^\star w\}$$

$L = (a + b)^\star$

Ejemplos

- Cualquier cadena de aes y bes debe generarse.
- La cadena vacía debe generarse:

$$S \to \varepsilon$$

- Si $w \in L$ entonces $wa \in L$

$$S \to Sa$$

- Si $w \in L$ entonces $wb \in L$

$$S \to Sb$$

- Ejemplo de derivación: $w = ababb$

$$S \to Sb \to Sbb \to Sabb \to Sbabb \to Sababb \to ababb$$

$L = \{a^i b^j \mid i, j \in \mathbb{N}, i \leq j\}$

Ejemplos

- La cadena vacía debe generarse ($i = j = 0$):

$$S \to \varepsilon$$

- Debe haber al menos tantas bes como aes, primero aes y luego bes:

$$S \to aSb$$

- Puede haber más bes al final:

$$S \to Sb$$

- Ejemplo de derivación: $w = aabbb$

$$S \to aSb \to aaSbb \to aaSbbb \to aabbb$$

$L = \{a^i b^j a^j b^i \mid i, j \in \mathbb{N}\}$

Ejemplos

- Primero generamos el centro de la palabra, $b^j a^j$:

$$S \to B \quad B \to bBa \quad B \to \varepsilon$$

- Después los extremos a^i, b^i:

$$S \to aSb$$

- Ejemplo de derivación: $w = aababb$

$$S \to aSb \to aaSbb \to aaBbb \to aabBabb \to aababb$$

$L = \{a^i b^i a^j b^j \mid i, j \in \mathbb{N}\}$

Ejemplos

- El lenguaje $\{a^i b^i \mid i \in \mathbb{N}\}$ se genera mediante:

$$P \to \varepsilon \qquad P \to aPb$$

- Para generar a L simplemente agregamos:

$$S \to PP$$

- Ejemplo de derivación: $w = aabbab$

$$S \to PP \to aPbP \to aPbaPb \to aaPbbaPb \to aaPbbab \to aabbab$$

$L = \{a^i b^i \mid i \in \mathbb{N}\} \cup \{b^i a^i \mid i \in \mathbb{N}\}$

Ejemplos

- El lenguaje $\{a^i b^i \mid i \in \mathbb{N}\}$ se genera mediante:

$$P \to \varepsilon \qquad P \to aPb$$

- El lenguaje $\{b^i a^i \mid i \in \mathbb{N}\}$ se genera mediante:

$$Q \to \varepsilon \qquad Q \to bQa$$

- Para generar a L simplemente agregamos:

$$S \to P \quad S \to Q$$

- Ejemplo de derivación: $w = bbbaaa$

$$S \to P \to aPb \to aaPbb \to aaaPbbb \to aaabbb$$

Correctud y completud

Diseño de gramáticas

- Si bien muchas veces el diseño de una gramática G para un lenguaje dado L es intuitivamente claro y correcto, esto debe mostrarse formalmente, mostrando que $L = L(G)$. Esto se hace, por supuesto, mostrando lo siguiente:
- Correctud: la gramática G genera únicamente cadenas de L, es decir, $L(G) \subseteq L$.
- Completud: toda cadena de L es generada por G, es decir, $L \subseteq L(G)$.

Lenguajes recursivamente enumerables o tipo 0

Jerarquía de Chomsky

Son aquellos lenguajes generados por una gramática sin restricciones adicionales.
Tales gramáticas pueden incluir reglas de la forma

$$\alpha \to \varepsilon$$

De manera que la gramática es capaz de borrar cadenas. Tales gramáticas se conocen como contraibles.
Ejemplo:

$$aS \to bSb,\ aSb \to \varepsilon,\ SbS \to bcS$$

Lenguajes recursivamente enumerables o tipo 0

Jerarquía de Chomsky

- La siguiente es una gramática de tipo 0:

$$S \to AT \quad A \to 0AO \quad A \to 1AI \quad O0 \to 0O$$

$$O1 \to 1O \quad I0 \to 0I \quad I1 \to 1I \quad OT \to 0T$$

$$IT \to 1T \quad A \to \varepsilon \quad T \to \varepsilon$$

- $L(G) = \{ww \mid w \in \{0,1\}^\star\}$
- La idea del diseño de esta gramática y la razón del nombre *recursivamente enumerable* se discutirán más adelante.

Lenguajes dependientes del contexto o tipo 1

Jerarquía de Chomsky

Son aquellos generados por gramáticas con todas sus producciones son de la forma

$$\alpha_1 A \alpha_2 \to \alpha_1 \beta \alpha_2$$

con $\alpha_1, \alpha_2 \in (V \cup T)^\star$, $A \in V$, $\beta \neq \varepsilon$.
Con la posible excepción de la regla $S \to \varepsilon$, en cuyo caso se prohibe la presencia de S a la derecha de las producciones.
Por ejemplo la siguiente gramática dependiente del contexto genera al lenguaje $L = \{a^i b^i c^i \mid i \geq 0\}$

$$S \to A \quad A \to aABC \mid abC \quad CB \to BC$$

$$bB \to bb \quad bC \to bc \quad cC \to cc$$

Lenguajes libres del contexto o tipo 2

Jerarquía de Chomsky

- Son aquellos generados por gramáticas con todas sus producciones de la forma

$$A \to \alpha$$

con $A \in V$, $\alpha \in (V \cup T)^\star$.

- Esta definición incluye a la regla $S \to \varepsilon$.
- La mayoría de las gramáticas para lenguajes de programación caen en esta categoría.

Lenguajes regulares o tipo 3

Jerarquía de Chomsky

Son aquellos generados por una gramática de una de las siguientes formas:

- Lineal por la derecha: todas las producciones de la forma

$$A \to aB \quad A \to a \quad A \to \varepsilon$$

con $A, B \in V,\ a \in T$

- Lineas por la izquierda: todas las producciones de la forma

$$A \to Ba \quad A \to a \quad A \to \varepsilon$$

con $A, B \in V,\ a \in T$

- No se permite mezclar ambos tipos de producciones.

Jerarquía de Chomsky

Observaciones

- Decimos que un lenguaje es de tipo i si y sólo si i es el índice mas grande tal que existe una gramática de tipo i que genera a L
- La jerarquía de gramáticas genera una jerarquía en los lenguajes generados:

$$\mathcal{L}_3 \subsetneq \mathcal{L}_2 \subsetneq \mathcal{L}_1 \subsetneq \mathcal{L}_0$$

- La jerarquía de Chomsky permite refinar la teoría de la computación clasificando lenguajes en función de los recursos computacionales necesarios para reconocerlos.

Gramáticas Regulares

- Una gramática regular es una gramática lineal por la derecha o lineal por la izquierda.
- No se permite mezclar ambos tipos de producciones.
- Se puede probar que toda gramática lineal por la izquierda es equivalente a una gramática lineal por la derecha.

Gramáticas Regulares

Lenguajes Regulares

- Decimos que un lenguaje L es regular si existe una gramática regular G que lo genere, es decir, si $L = L(G)$.
- Si L es generado por una gramática de tipo i, no se puede asegurar de inmediato que L sea un lenguaje de tipo i. Debe asegurarse que i es máximo.

$L = 0^*10^*10^*$

Ejemplos

L es generado por:

$$\begin{aligned} S &\rightarrow A1A1A \\ A &\rightarrow 0A \mid \varepsilon \end{aligned}$$

esta gramática no es regular, pero el lenguaje si lo es al existir una gramática regular equivalente:

$$\begin{aligned} S &\rightarrow 0S \mid 1A \\ A &\rightarrow 0A \mid 1B \\ B &\rightarrow 0B \mid \varepsilon \end{aligned}$$

$L = (a + b)^{\star} b$

Ejemplos

L es generado por:

$$\begin{aligned} S &\rightarrow aS \mid bC \\ C &\rightarrow bC \mid aS \mid \varepsilon \end{aligned}$$

Lenguajes y gramáticas regulares

AF $\Rightarrow$ GR

Dado un AF $M = \langle Q, \Sigma, \delta, q_0, F \rangle$ existe una gramática regular $G = \langle V, T, S, P \rangle$ tal que $L(M) = L(G)$. Es decir, todo lenguaje regular es generado por una gramática regular.
Definimos a G como sigue:

- Suponemos s.p.g. que no hay ε-transiciones.
- $V = Q \quad T = \Sigma \quad S = q_0$
- P se define como sigue:
  - Si $p \in \delta(q, a)$ entonces agregamos $q \to ap$ a P.
  - Si $q_f \in \delta(q, a)$ con $q_f \in F$ entonces agregamos $q \to a$.

Lenguajes y gramáticas regulares

GR $\Rightarrow$ AF

Dada una gramática regular $G = \langle V, T, S, P \rangle$ existe un AF $M = \langle Q, \Sigma, \delta, q_0, F \rangle$ tal que $L(M) = L(G)$. Es decir todo lenguaje generado por una gramática regular es un lenguaje regular.
Definimos a M como sigue:

- Suponemos s.p.g. que G es lineal derecha.
- $Q = V \cup \{q_F\} \quad \Sigma = T \quad q_0 = S \quad F = \{q_F\}$
- δ se define como sigue:
  - Si $A \to aB \in P$ entonces $B \in \delta(A, a)$.
  - Si $A \to a \in P$ entonces $q_F \in \delta(A, a)$.
  - Si $A \to \varepsilon \in P$ entonces $q_F \in \delta(A, \varepsilon)$.

Gramáticas libres de contexto

Definición

Una gramática es libre o independiente del contexto si todas sus producciones son de la forma

$$A \to \alpha$$

con $A \in V$, $\alpha \in (V \cup T)^\star$.
Esta definición incluye a la regla $S \to \varepsilon$.
Obsérvese que en particular toda gramática regular es libre de contexto.

Gramáticas libres de contexto

Ejemplos

- $L = a^\star$

$$S \to aS \mid \varepsilon$$

- $L = a^\star b^\star$

$$\begin{aligned} S &\to aS \mid bA \mid \varepsilon \\ A &\to bA \mid b \mid \varepsilon \end{aligned}$$

- $L = 0^+ 1^+$

$$\begin{aligned} S &\to CU \\ C &\to 0C \mid 0 \\ U &\to 1U \mid 1 \end{aligned}$$

Gramáticas libres de contexto

Ejemplos

- $L = \{a^n b a^m \mid n, m \geq 1\} = a^+ b a^+$

$$\begin{aligned} S &\rightarrow aS \mid aB \\ B &\rightarrow bC \\ C &\rightarrow aC \mid a \end{aligned}$$

- $L = \{a^n b^n \mid n \in \mathbb{N}\}$ que no es regular

$$S \rightarrow aSb \mid \varepsilon$$

- $L = \{w \in \{a, b\}^\star \mid w = w^R\}$ que no es regular

$$S \rightarrow aSa \mid bSb \mid a \mid b \mid \varepsilon$$

Derivaciones por la izquierda

GLC

Una derivación $S \rightarrow^{\star} w$ es una derivación por la izquierda si en cada paso se reescribe la variable mas a la izquierda en la palabra.
En la gramática

$$S \rightarrow aAs \mid a \qquad A \rightarrow SbA \mid SS \mid ba$$

tenemos la siguiente derivación por la izquierda de $aabbaa$.

$$S \rightarrow aAS \rightarrow aSbAS \rightarrow aabAS \rightarrow aabbaS \rightarrow aabbaa$$

Derivaciones por la derecha

GLC

Una derivación $S \to^\star w$ es una derivación por la derecha si en cada paso se reescribe la variable mas a la derecha en la palabra.
En la gramática

$$S \to aAs \mid a \qquad A \to SbA \mid SS \mid ba$$

tenemos la siguiente derivación por la derecha de *aabbaa*.

$$S \to aAS \to aAa \to aSbAa \to aSbbaa \to aabbaa$$

Árboles de derivación

GLC

- Los árboles de derivación o árboles sintácticos son un mecanismo para representar las derivaciones de gramáticas libres de contexto.
- En compiladores se utilizan para el análisis sintáctico de programas fuente (parsing) y sirven de base para la generación de código.
- Puede ser que dos derivaciones distintas tengan el mismo árbol.

Árboles de derivación

GLC

- Puede haber mas de un árbol de derivación para una cadena.
- Lo ideal es que cada cadena tenga sólo un árbol asociado, esto implica que el lenguaje no es ambiguo.
- Desafortunadamente existen lenguajes ambiguos.

Construcción de árboles de derivación

GLC

Dada una gramática libre de contexto $G = \langle V, T, S, P \rangle$, un árbol de derivación en G se construye como sigue:

- La raiz contiene al símbolo inicial S.
- Cada nodo interior contiene una variable
- Cada hoja contiene un símbolo de $V \cup T \cup \{\varepsilon\}$.
- Si un nodo interior contiene una variable A entonces sus hijos contienen símbolos (de izquierda a derecha) $a_1, \ldots, a_n$ si y sólo si $A \to a_1 a_2 \ldots a_n$ está en P.
- La palabra generada se puede leer al leer las hojas de izquierda a derecha.

Ambigüedad

GLC

- Una gramática se dice ambigua si existe una palabra w con dos o más árboles de derivación distintos.
- En general una palabra puede tener mas de una derivación, pero un sólo árbol, en tal caso no hay ambigüedad.
- Algunas veces se puede suprimir la ambigüedad directamente.
- Sin embargo no hay un algoritmo para remover ambigüedad.
- Pero aún, hay lenguajes cuya ambigüedad es inevitable.

Ejemplos

Ambigüedad

$$S \to AA \quad A \to aSa \mid a$$

La palabra a^5 tiene las siguientes derivaciones:

- $S \to AA \to aA \to aaSa \to aaAAa \to aaaAa \to aaaaa$
- $S \to AA \to aSaA \to aAAaA \to aaAaA \to aaaaA \to aaaaa$
- Las dos derivaciones son por la izquierda y generan árboles distintos.

Lenguajes Ambiguos

Ambigüedad

- Un lenguaje L es ambiguo si existe una gramática ambigua G que genera a L.
- $L = \{a^{2+3i} \mid i \geq 0\}$ es ambiguo.

- Un lenguaje es inherentemente ambiguo si todas las gramáticas que lo generan son ambiguas.
- $L = \{a^n b^n c^m d^m \mid n, m \geq 1\} \cup \{a^n b^m c^m d^n \mid n, m \geq 1\}$ es inherentemente ambiguo.

$L = \{a^{2+3i} \mid i \geq 0\}$

Lenguajes ambiguos

L es ambiguo por se generado por la gramática ambigua

$$S \to AA \quad A \to aSa \mid a$$

Sin embargo este lenguaje también es generado por una gramática no ambigua:

$$S \to aa \mid aaU \qquad U \to aaaU \mid aaa$$

en este caso la derivación de a^5 es:

$$S \to aaU \to aaaaa$$

por lo tanto L no es un lenguaje inherentemente ambiguo

$L = \{a^n b^n c^m d^m \mid n, m \geq 1\} \cup \{a^n b^m c^m d^n \mid n, m \geq 1\}$

Lenguajes inherentemente ambigüos

L es generado por la gramática:

$$S \to AB \mid C \quad A \to aAb \mid ab \quad B \to cBd \mid cd$$
$$C \to aCd \mid aDd \quad D \to bDc \mid bc$$

La cadena *aabbccdd* tiene dos derivaciones por la izquierda:

$S \to AB \to aAbB \to aabbB \to aabbcBd \to aabbccdd$

$S \to C \to aCd \to aaDdd \to aabDcdd \to aabbccdd$

Probar la ambiguedad inherente es complicado.